逻辑回归

1. 概念

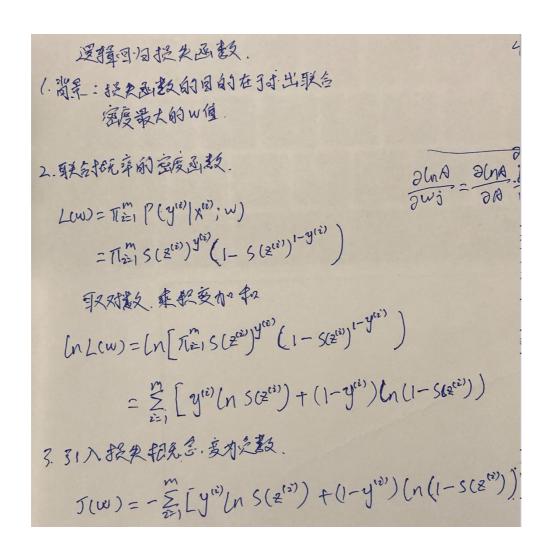
1.1. 概念:逻辑回归是一个分类模型,通过给样本数据打分进行分类, 大于阀值归一类,反之亦然

导入:from sklearn.linear_model import LogisticRegreession 引入 sigmoid 函数:sigmoid 函数是由伯努利分布推导出来的,在一个取值连续的变量上(逻辑回归的预测值 Y),可以将其映射到 0~1 的区间上,也就是概率,当概率大于 0.5 时归为一类,反之亦然,这样就对自变量 x(特征)起到了分类作用

注:求出的概率是归为正例的概率

2. 逻辑回归的损失函数由来和求解

2.1 损失函数的由来



损失函数的求解

$$\begin{split} &\mathcal{J}(\omega) = -\frac{\mathcal{J}}{2} \left[y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\mathcal{J}}{2} \left[y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = \frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = \frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = \frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = \frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = \frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-y^{(0)}) \ln (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)})) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \right] \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)} \ln S(z^{(0)}) + (1-S(z^{(0)}) \right) \\ &\mathcal{J}(\omega) = -\frac{\partial}{\partial u_j} \left(-y^{(0)}$$

3. 逻辑回归为什么使用 sigmoid 函数

3.1 sigmoid 函数推导

Sigmoid 函数推了 省等:肉的努力分布可以维导出 Sigmis 从函数 伯名为郑的质量函数 f(x)= px. (1-p) 1-x du) = px. [1-p) 1-x =eln[px.(1-p) 1-x] = ex. (np + (1-x) (n(1-p) = + (n(1-p) - x (n(1-p) $= e^{x \cdot (nP + (n(1-P) - x(n(1-P)) - x(n(1-P))}$ $= e^{x \cdot (nP - (n(1-P)) + (n(1-P))}$ $= e^{x \cdot (nP + (n(1-P)) + (n(1-P))}$ 金月=1十一 $e^{3} = \frac{P}{1-P}$ eⁿ(1-1²)= |² P = 1+eⁿ = 1+e⁻ⁿ