

线性回归

1. 多元线性回归的向量表示法

1.1 多元线性回归的向量表示推导

多元线性回归推导.

$$\hat{y} = w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n + b$$

① 将 w_1, w_2, \dots, w_n 用向量表示
即 $\vec{w} = (w_1, w_2, w_3, \dots, w_n)^T$

② 将 x_1, x_2, \dots, x_n 用向量表示
即 $\vec{x} = (x_1, x_2, x_3, \dots, x_n)^T$

③ 将方程变换形式得.

$$\hat{y} = \sum_{j=1}^n w_j \cdot x_j + b$$

④ 由①, ②向量化代入③

$$\hat{y} = \vec{w}^T \cdot \vec{x} + b$$

⑤ 进一步简化, 令
 $x_0 = 1, w_0 = b$ (目的是将截距项 b 并入方程中)

得: $\hat{y} = \vec{w}_0 \cdot x_0 + w_1 \cdot x_1 + w_2 \cdot x_2 + \dots + w_n \cdot x_n$

$$= \sum_{j=0}^n w_j \cdot x_j$$
$$= \vec{w}^T \cdot \vec{x}$$

2. 损失函数的由来和求解

2.1 损失函数的由来

极大似然推导.

表示预测值

背景: 线性回归模型为 $y = \theta^T X \rightarrow$ 可参线性回归模型推导.

误差总称为 $|\theta^T X - y_i|$, 误差是满足高斯分布的.

① 则由误差和高斯分布公式可得.

似然函数. \nearrow 已知量 \nearrow 确定值 \nearrow 自变量.

$$L(\theta) = \prod_{i=1}^m P(y^{(i)} | x^{(i)}; \theta) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

② 对似然函数取对数, 累加更易计算.

$$\log L(\theta) = \log \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

\Downarrow

$$= \sum_{i=1}^m \log \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(y^{(i)} - \theta^T x^{(i)})^2}{2\sigma^2}\right)$$

\Downarrow

$$= m \log \frac{1}{\sqrt{2\pi}\sigma^2} - \frac{1}{\sigma^2} \cdot \frac{1}{2} \sum_{i=1}^m (y^{(i)} - \theta^T x^{(i)})^2$$

$$\text{loss}(y_j, \hat{y}_j) = J(\theta) = \frac{1}{2} \sum_{i=1}^m (\overset{\nearrow \text{预测值 } \hat{y}}{h_\theta(x^{(i)})} - y^{(i)})^2$$

上述阐述了如何由高斯分布推导出损失函数.

损失函数的求解

损失函数求导.

矩阵转置与原矩阵相乘一定可以
相乘.

$$J(\theta) = \frac{1}{2} \sum_{i=1}^m (y - y_i)^2 = (X\theta - y_i)^2 = (X\theta - y_i)^T (X\theta - y_i)$$

$$J(\theta) = X^T \theta^T X \theta - \sum_i X^T \theta^T y_i - y_i^T X \theta + y_i^T y_i$$

$$\frac{\partial J(\theta)}{\partial \theta} = \frac{\partial X^T \theta^T X \theta}{\partial \theta} - \frac{\partial X^T y_i \theta^T}{\partial \theta} - \frac{y_i^T X \theta}{\partial \theta} + 0$$

$$\frac{\partial J(\theta)}{\partial \theta} = (X^T X + X^T) \theta - X^T y_i - y_i X^T$$

$$= 2 X^T X \theta - 2 X^T y_i$$

$$= 2 (X^T X \theta - X^T y_i)$$

$$\frac{1}{2} \frac{\partial J(\theta)}{\partial \theta} = 0, \text{ 求导}$$

$$2 (X^T X \theta - X^T y_i) = 0$$

$$\theta = \frac{X^T y_i}{X^T X}$$

3. 回归模型的评估

3.1 MSE(mean squared error) : 平均平方误差

原理：所有样本数据误差（真实值与预测值之差）的平方和，然后取均值

公式如下

$$MSE = \frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2$$

3.2 RMSE(root squareed error)：平均平方误差的平方根

原理：在 MSE 的基础上开根号

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)})^2}$$

3.3 MAE(mean absolute error)：平均绝对值误差，为所有样本数据误差的绝对值和

$$MAE = \frac{1}{m} \sum_{i=1}^m |y^{(i)} - \hat{y}^{(i)}|$$

3.4 R^2 ：决定系数，用来表示模型拟合的好坏，值越高拟合越好，在训练集中， R^2 的取值范围为[0,1]，在测试集(未知数据)中， R^2 的取值范围是 $[-\infty, 1]$ ，

3.5 各个评估标准的使用方法

```
1 from sklearn.metrics import mean_squared_error, mean_absolute_error, r2_score
2
3 print("均方误差(MSE): ", mean_squared_error(y_test, y_hat))
4 print("根均方误差(RMSE): ", np.sqrt(mean_squared_error(y_test, y_hat)))
5 print("平均绝对值误差(MAE): ", mean_absolute_error(y_test, y_hat))
6 print("训练集 $R^2$ : ", r2_score(y_train, lr.predict(X_train)))
7 print("测试集 $R^2$ : ", r2_score(y_test, y_hat))
8 # socre其实求解的就是 $r^2$ 的值。但是注意，r2_score方法与score方法传递参数的内容是不同的。
9 print("训练集 $R^2$ : ", lr.score(X_train, y_train))
10 print("测试集 $R^2$ : ", lr.score(X_test, y_test))
```